



UNIVERSIDADE FEDERAL DO PARÁ
INSTITUTO DE TECNOLOGIA FACULDADE DE ENGENHARIA DA
COMPUTAÇÃO E TELECOMUNICAÇÕES

AMANDA GABRIELLY PRESTES LOPES - 202207040043

ALGORITMO GENÉTICO

BELÉM - PA
2025

AMANDA GABRIELLY PRESTES LOPES - 202207040043

ALGORITMO GENÉTICO

Relatório da primeira atividade avaliativa da disciplina de Técnicas de Otimização ministrada pelo professor Roberto Limão para o curso de Engenharia de Telecomunicações do Instituto de Tecnologia da Universidade Federal do Pará - Campus Belém.

BELÉM - PA

2025

Sumário

1	INTRODUÇÃO	3
1.1	Visão Geral	3
1.2	Objetivos	3
2	DESENVOLVIMENTO	4
2.1	Metodologia	4
3	Resultados	5
3.1	Explicação do Código	5
3.1.1	Análise	6
4	Conclusão	9
	Referências	10

1 INTRODUÇÃO

1.1 Visão Geral

Este trabalho foca na aplicação de um Algoritmo Genético (AG), uma meta-heurística bioinspirada, para resolver um problema de otimização contínua. A meta principal é encontrar o valor máximo de uma função matemática complexa, a função $F6(x,y)$, em um domínio de busca predefinido. A abordagem do AG, inspirada nos princípios de seleção natural e genética, permite a busca por soluções de forma adaptativa e probabilística, diferente dos métodos de otimização tradicionais (MITCHELL, 1996). O trabalho explora como os operadores genéticos, como seleção, cruzamento e mutação, interagem para guiar uma população de soluções candidatas em direção a um ótimo global (GOLDBERG, 1989; DAVIS, 1991).

Além da otimização, o cerne deste estudo é a análise visual e quantitativa do comportamento do AG. Isso inclui a avaliação do desempenho por meio de métricas como aptidão máxima, aptidão média e diversidade da população ao longo das gerações. O trabalho também demonstra, de forma prática, como a representação visual da paisagem de aptidão (com gráficos 3D e de curvas de nível) e da evolução da população pode fornecer insights valiosos sobre a dinâmica do algoritmo.

Código completo e imagens estarão disponíveis no repositório do Github abaixo:

<https://github.com/a-mand/algoritmoGenetico>

1.2 Objetivos

Os objetivos deste trabalho são duplos, divididos em uma abordagem fundamental e uma avançada:

Avaliar o desempenho de um Algoritmo Genético Padrão:

- Implementar um AG com operadores genéticos clássicos (seleção por roleta, cruzamento de um ponto e mutação com taxa fixa de 1%).
- Monitorar a evolução da aptidão máxima e média da população para verificar a convergência do algoritmo.
- Calcular e analisar a diversidade da população (usando o desvio padrão da aptidão) para entender como a variabilidade genética se comporta durante o processo de otimização.
- Gerar gráficos detalhados que ilustram a aptidão, a diversidade e a superfície da função $F6(x,y)$ para uma análise abrangente.

2 DESENVOLVIMENTO

2.1 Metodologia

A metodologia aplicada neste trabalho baseia-se na implementação e análise computacional de um Algoritmo Genético (AG) para otimizar a função de avaliação $F6(x,y)$, dada abaixo. A abordagem metodológica foi dividida em duas etapas principais, correspondentes aos objetivos propostos. A linguagem de programação Python foi utilizada para toda a implementação, com as bibliotecas NumPy para operações matemáticas eficientes e Matplotlib para a geração de gráficos.

$$F6(x, y) = 0.5 - \frac{\left[\sin \left(\sqrt{x^2 + y^2} \right) \right]^2 - 0.5}{[1 + 0.001(x^2 + y^2)]^2}$$

1. Implementação e Análise do AG Padrão

A primeira fase consistiu na criação de um AG fundamental, cujos parâmetros e operadores foram configurados conforme a seguir:

- As variáveis de otimização contínuas, x e y , com domínio em $[-100, 100]$, foram codificadas em um cromossomo binário. Com uma precisão de 5 casas decimais, o número mínimo de bits para cada variável foi calculado em 25, resultando em um cromossomo total de 50 bits.
- A função $F6(x,y)$ foi diretamente utilizada como a função de aptidão (ou fitness). A aptidão de cada indivíduo da população foi avaliada decodificando seu cromossomo binário para os valores reais de x e y .
- Uma população de 100 indivíduos foi gerada aleatoriamente na primeira iteração. O processo foi executado por um total de 500 gerações. Para garantir a reprodutibilidade dos resultados, uma semente fixa (seed) foi utilizada para o gerador de números pseudoaleatórios.
- Os principais operadores de reprodução foram:
 - *Seleção por Roleta*: Indivíduos com maior aptidão tiveram uma probabilidade proporcionalmente maior de serem selecionados como pais para a próxima geração.
 - *Cruzamento de um Ponto*: Com uma taxa de cruzamento de 80%, os pais selecionados foram submetidos a um cruzamento de um ponto, onde um ponto de corte aleatório foi determinado para a troca de material genético.
 - *Mutação*: Uma taxa de mutação fixa de 1% foi aplicada a cada bit dos cromossomos gerados, garantindo a introdução de novas variações genéticas.

2. Implementação e Análise da Mutação Adaptativa

Na segunda etapa, a metodologia foi aprimorada para incorporar uma estratégia de mutação adaptativa, visando demonstrar como parâmetros dinâmicos podem influenciar o desempenho do AG. A taxa de mutação, anteriormente fixa, tornou-se variável, seguindo a seguinte lógica:

- A execução iniciou com uma taxa de mutação padrão de 1% (taxa inicial).
- A cada geração, a aptidão máxima da população foi monitorada.
- Quando a aptidão máxima atingiu um limiar de 0.99, a taxa de mutação foi aumentada para 5% (taxa adaptativa) e permaneceu nesse valor até o final da simulação. O momento exato dessa mudança foi registrado.

3 Resultados

A segunda tarefa deste trabalho tem um objetivo duplo e complementar: (1) implementar uma estratégia de mutação adaptativa, onde a taxa de mutação do AG é alterada dinamicamente, e (2) analisar o impacto dessa mudança na evolução da aptidão e da diversidade da população. A principal métrica de análise para esta seção é a diversidade, calculada como o desvio padrão da aptidão da população a cada geração.

3.1 Explicação do Código

1. Parâmetros e Variáveis de Controle

Esta seção do código define os parâmetros que regem o comportamento adaptativo do AG. As variáveis de controle são essenciais para gerenciar a mudança de estado do algoritmo.

- `INITIAL_MUTATION_RATE`: A taxa de mutação inicial (0.01), utilizada na fase de exploração.
- `ADAPTIVE_MUTATION_RATE_HIGH`: A nova taxa de mutação (0.05) que será ativada.
- `APTITUDE_THRESHOLD_HIGH`: O limiar de aptidão (0.99) que, quando alcançado pela melhor solução, aciona a mudança na taxa de mutação.
- `current_mutation_rate`: Uma variável dinâmica que armazena a taxa de mutação atual.
- `mutation_applied_generation`: Registra a geração em que a mutação foi ativada.

2. Lógica de Ativação da Mutação

O coração da estratégia adaptativa reside na lógica condicional inserida no ciclo principal do algoritmo. A cada geração, o AG verifica se a melhor aptidão da população ('current_best_fitness') atingiu o limiar ('APTITUDE_THRESHOLD_HIGH'). A condição 'mutation_applied_generation is None' garante que a mudança seja um evento único.

```

1 current_mutation_rate = INITIAL_MUTATION_RATE
2 mutation_applied_generation = None
3
4 # Trecho do loop principal
5 if current_best_fitness >= APTITUDE_THRESHOLD_HIGH and
   ↳ mutation_applied_generation is None:
6     current_mutation_rate = ADAPTIVE_MUTATION_RATE_HIGH
7     mutation_applied_generation = generation
8     print(f"Geração_{generation}: Melhor aptidão atingiu...")

```

3. Operador de Mutação Dinâmico

Para que a lógica de ativação tenha efeito, o operador de mutação é projetado para ser dinâmico. A função 'mutation()' aceita um parâmetro de taxa, 'rate', que é o valor de 'current_mutation_rate'. Desta forma, a taxa de mutação usada para gerar os filhos é sempre a taxa atual do algoritmo, permitindo que a mudança ocorra de forma fluida.

```

1 def mutation(chromosome, rate):
2     for i in range(len(chromosome)):
3         if np.random.rand() < rate:
4             chromosome[i] = 1 - chromosome[i]
5     return chromosome
6
7 # Chamada no ciclo principal
8 child1 = mutation(child1, current_mutation_rate)
9 child2 = mutation(child2, current_mutation_rate)

```

3.1.1 Análise

A Figura 1 ilustra o principal resultado da segunda parte do trabalho: a evolução da aptidão e da diversidade da população sob uma estratégia de mutação adaptativa. O gráfico plota os valores de aptidão e diversidade em uma escala normalizada, o que permite a comparação direta entre as métricas.

A análise do gráfico revela a dinâmica da estratégia aplicada:

- **Convergência da Aptidão (Linha Preta):** A curva da aptidão máxima normalizada ('Aptidão Máxima Normalizada') demonstra uma rápida convergência para




Figura 1: Evolução da Aptidão e Diversidade com Mutação Adaptativa.

o valor 1,0, alcançando este platô por volta da Geração 31. Este comportamento confirma que a fase de exploração inicial do AG foi bem-sucedida, com o algoritmo encontrando a solução de alta qualidade em poucas gerações.

- **Comportamento da Diversidade (Linha Vermelha):** A curva de diversidade ('Diversidade Normalizada', medida pelo desvio padrão da aptidão), mostra um padrão inicial de decaimento, o que é esperado à medida que a população se torna mais homogênea em torno das melhores soluções.
- **O Impacto da Mutação Adaptativa:** O ponto de virada na simulação é marcado pela linha vertical tracejada na Geração 31. Este é o momento em que a aptidão máxima atingiu o limiar de 0.99, ativando a lógica de mutação adaptativa. Como resultado direto, observa-se um pico imediato e acentuado na diversidade da população, que salta para um nível elevado e continua a flutuar significativamente durante o restante das gerações.
- **Aptidão Média (Linha Verde):** A aptidão média da população também é exibida. Ela segue a aptidão máxima, mas se estabiliza em um valor mais baixo na escala normalizada, o que é esperado, pois ela representa a média de todos os indivíduos, e não apenas o melhor.

A Figura 2 oferece uma visão ampliada e focada no momento crucial em que a taxa de mutação adaptativa é ativada. O gráfico de "zoom" cobre as gerações de 20 a 55,

permitindo uma análise minuciosa da causa e efeito da intervenção do algoritmo.

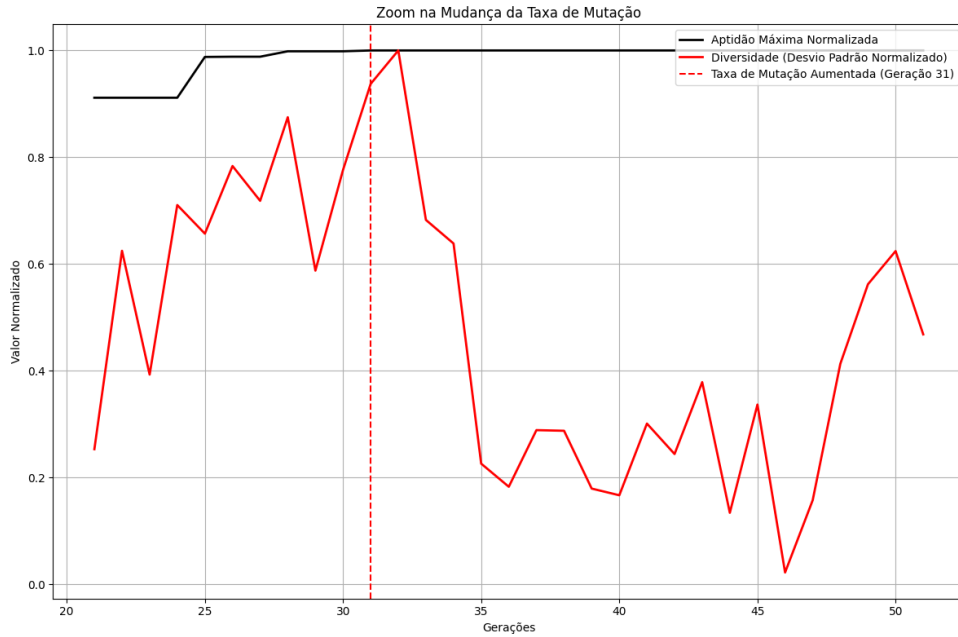


Figura 2: Gráfico ampliado, focado na região de aplicação da mutação adaptativa.

A interpretação do gráfico se divide em três fases:

- **Fase de Convergência (Gerações 20-31):** Neste período, a aptidão máxima (Aptidão Máxima Normalizada) sobe rapidamente e atinge o platô de 1,0, que é o máximo global da função. Simultaneamente, a diversidade (Diversidade Normalizada) começa a decair, indicando que a população está se tornando homogênea ao se aglomerar em torno da solução ótima. A convergência da aptidão é o gatilho para a próxima fase.
- **O Evento da Mutação (Geração 31):** O momento exato da aplicação da mutação adaptativa é marcado pela linha vertical tracejada. O algoritmo detectou que a aptidão máxima atingiu o limiar de 0,99, e, conforme a lógica programada, a taxa de mutação foi aumentada. O impacto dessa mudança é imediatamente visível na curva de diversidade.
- **Fase Pós-Mutação (Gerações 32-55):** Após a Geração 31, a aptidão máxima permanece estável no valor 1,0 (uma vez que o máximo já foi alcançado). No entanto, a curva de diversidade demonstra uma reação imediata e significativa, exibindo um pico acentuado. Este aumento é a prova direta de que a maior taxa de mutação reintroduziu variação genética na população. Embora a aptidão máxima não tenha mudado, o AG agora opera com um nível de diversidade renovado, mantendo a capacidade de explorar o espaço de busca de forma mais robusta e evitando uma estagnação completa.

4 Conclusão

A implementação e análise de um Algoritmo Genético (AG) para a otimização da função $F6(x,y)$ demonstraram a eficácia dessa meta-heurística na busca por soluções ótimas em problemas contínuos. A primeira fase do trabalho, com a configuração de um AG padrão e taxa de mutação fixa, comprovou a sua capacidade de convergência. O algoritmo foi capaz de encontrar o máximo global da função ($Z = 1.0$) em poucas gerações, atingindo um estado de estabilidade que manteve a solução ótima até o final da simulação.

A segunda fase, focada na estratégia de mutação adaptativa, revelou insights cruciais sobre o equilíbrio entre exploração e exploração. A análise da diversidade da população, em conjunto com a aptidão, demonstrou que, em um AG padrão, a convergência para um ótimo (exploração) leva a uma perda natural de diversidade. No entanto, a implementação da mutação adaptativa, ativada ao atingir um limiar de aptidão, funcionou como um mecanismo eficaz para reintroduzir variação genética (exploração) no momento mais oportuno.

O pico na diversidade da população após a ativação da mutação adaptativa na Geração 31 é uma evidência clara de que essa estratégia evita a estagnação completa do algoritmo. Embora a aptidão máxima não tenha melhorado (uma vez que o ótimo global já havia sido encontrado), a população se tornou mais robusta, mantendo a capacidade de explorar o espaço de busca e de se adaptar a possíveis mudanças no ambiente. Em suma, a abordagem adaptativa se mostra um aprimoramento valioso, oferecendo um controle dinâmico que pode ser fundamental para evitar a convergência prematura em problemas de otimização mais complexos.

Referências

- DAVIS, L. **Handbook of Genetic Algorithms**. [S.l.]: Van Nostrand Reinhold, 1991.
- GOLDBERG, D. E. **Genetic Algorithms in Search, Optimization, and Machine Learning**. [S.l.]: Addison-Wesley, 1989.
- MITCHELL, M. **An Introduction to Genetic Algorithms**. [S.l.]: MIT Press, 1996.